



PROJEKTBERICHT

2023-II

Wir nutzen die Technologie! Erste Schritte in die Modellierung
linguistischer Daten

Projektleitung
Erdin Mujezinović

Projektbericht – Wir nutzen die Technologie! Erste Schritte in die Modellierung von linguistischen Daten

Severin Sieber^{a*}, Kseniya Rudakova^{a†}, Erdin Mujezinović^{a‡}

^aInstitut für Linguistik, Heinrich-Heine-Universität Düsseldorf

05.Mai.2025

Zusammenfassung

Für die linguistische Forschung findet computergestützte Arbeit immer häufiger Anwendung. Dies stellt eine große Herausforderung für Studierende der Linguistik dar, da den Studierenden oft Informatikgrundlagen fehlen. Hier setzt das E-Learning Projekt „Wir nutzen die Technologie! Erste Schritte in die Modellierung von linguistischen Daten“ an, und vermittelt kleinschrittig anhand von ausgewählten Lernmodellen – EDL, NDL, und LDL – die Grundlagen der Computermodellierung linguistischer Daten. Das Projekt wurde zwischen dem 15.Oktober.2023 und den 15.Oktober.2024 durch das E-Learning Förderfonds der Heinrich-Heine-Universität Düsseldorf (Deutschland) gefördert. Das Projekt ist fertiggestellt und steht Studierenden und Lehrenden der Heinrich-Heine Universität zur Verfügung. Der vorliegende Projektbericht bietet einen Überblick über die Ausgangslage, Ziele, Inhalte und Ergebnisse des Projekts.

*Für den Inhalt zuständig

†Für den Inhalt zuständig

‡Projektleiter

Inhaltsverzeichnis

1	Ausgangslage	1
2	Ziel und Zielgruppe	2
3	Inhalt	2
4	Umsetzung	3
5	Ergebnisse	3
6	Verfügbarkeit	4
7	Ausblick	4
8	Autorenbeiträge	4
9	Danksagung	4
10	Anhang	I

1 Ausgangslage

Problem Computerkompetenzen werden innerhalb der Geisteswissenschaften immer wichtiger. Dies trifft auch auf die linguistische Forschung zu. Leider fehlt es vielen Linguistik-Studierenden an Informatikgrundlagen, um computergestützte Methoden nachzuvollziehen und selbst anzuwenden. Dozierende müssen dann oft das Niveau in den Seminaren drosseln – zum Leidtragen fortgeschrittener Studierender. Ein noch größeres Problem ist jedoch, dass es oft nicht möglich ist, diese Lücken während der Seminarzeiten zu schließen. Dies führt dazu, dass Studierende in einer Negativspirale stecken bleiben: Die Schwierigkeit der Inhalte wird überschätzt, während die eigenen Fähigkeiten unterschätzt werden. Das hat dann zur Folge, dass zukünftige Kurse mit computationellen Elementen eher vermieden werden. Der E-Learning Kurs soll dieser ungünstigen Lage entgegenwirken.

Lösung Der E-Learning Kurs schließt eine wichtige Lücke innerhalb des Institut für Linguistik, indem ein sanfter Einstieg in die linguistische Computermodellierung angeboten wird. Durch Lehrmaterialien, bestehend aus Skripten, Codebeispielen, Visualisierungen, interaktiven Aufgaben (H5P) und Videoanleitungen, werden Studierende in die Grundlagen der R-Programmiersprache und Computermodellierung linguistischer Daten eingeführt. R wird häufig für die statistische Analyse linguistischer Daten eingesetzt. Die vorgestellten Computermodelle wurden unter anderem als R Pakete implementiert. Diese Modelle sind besonders interessant, da diese in der aktuellen linguistischen Forschung angewandt werden, um verschiedene Aspekte des linguistischen Wissens von Sprecher und Sprecherinnen zu erklären. Der Erwerb dieser Methoden ist ein wertvolles Werkzeug für die eigene Forschung. Die Modellierung größerer Datensätze zum Zwecke des Verständnisses von Sprachstrukturen und Sprachgebrauch findet immer öfter Anwendung. Sowohl kleinere, als auch größere Modellierungen sind mit diesen Modellen möglich. Sowohl innerhalb, als auch außerhalb der Wissenschaft werden Kompetenzen, die für die Implementierung solcher Modelle benötigt werden, von Arbeitgebern gerne gesehen, z.B. bei der Arbeit als Data Analyst.

Kompetenzen Studierenden und Dozierenden wird eine Ressource zur Verfügung gestellt, die für verschiedene Bereiche des Studiums verwendet werden kann, z.B. Aufbau-seminare. Studierenden lernen u.a. die Grundlagen der R-Programmierung kennen, wie Error-driven Learning funktioniert, und wie Lernmodelle für linguistische Fragestellungen genutzt werden können. Die Kompetenzen können für eigene Projektarbeiten genutzt werden, aber auch als Ergänzung für sowohl praktischere als auch theoretischere Kurse zu den Themen Lernmodelle und Computationelle Modellierung innerhalb der Linguistik. Zusätzlich dient der Kurs als sanfter Einstieg in das Themenfeld Maschinelles Lernen. Studierende lernen durch die E-Learning Materialien Grundlagen in der Programmierung mit R, womit eine solide Basis für Quantitative Kurse geschaffen wird (unter anderem Statistik für Linguistik, Kurse in experimentelle Phonetik und Phonologie, Korpuslinguistik und Computermodellierung). Lehrende können die Materialien aktiv in ihrer Lehre einbinden: Entweder als Ergänzungsmaterial, oder um bestimmte Inhalte zu vertiefen, bzw. auf außerhalb der Kurszeiten zu verlagern. Dadurch können sich Dozierende auf spezifischere Anwendungsbeispiele während der Kurszeiten konzentrieren. Gleichzeitig erhalten Studierende eine wichtige Ressource, um sowohl theoretische, als auch praktische Aspekte der Computermodellierung zu üben, oder Versäumtes in Eigenregie nachzuarbei-

ten. Durch die Kursinhalte können die technischen Fähigkeiten und das Verständnis für Datenstrukturen, sowie computationeller Verarbeitung von Sprache, verbessert werden. Dadurch können sich Linguistik-Studierende auch besser auf dem Arbeitsmarkt positionieren.

2 Ziel und Zielgruppe

Zielgruppe sind primär BA Linguistik (integrativ/Ergänzungsfach) Studierende **ohne Informatikvorkenntnisse**. Auch eignen sich die Inhalte als Ergänzung für BA Computerlinguistik, oder MA Linguistik Studierende. Die Anzahl an Linguistik Studierenden liegt bei 120-200 innerhalb der Basismodule. In den Aufbaumodulen sind es 20-30 Studierende pro Aufbauseminar. Die Anzahl an Computerlinguistik BA und Linguistik Master Studierende sind mit denen der Aufbauseminare vergleichbar. Ebenfalls sind für benachbarte Philologien die E-Learning Inhalte womöglich interessant. Die Inhalte sind für die linguistischen Teilbereiche Morphologie, Syntax, Phonetik und Phonologie, sowie Computerlinguistik relevant. Zusätzlich sind diese für die Psycholinguistik und Kognitionswissenschaft interessant, da innerhalb der Lernmodelle Erkenntnisse aus der Lerntheorie einfließen. Die Inhalte sind in erster Linie an Studierende der Aufbaumodule, welche üblicherweise ab dem 3.Semester belegt werden, gerichtet. Jedoch können Studierende vom 1.Semester an mit den Inhalten arbeiten, da nur ein grundlegendes Verständnis in Allgemeiner Linguistik vorausgesetzt wird. Der Kurs soll demnach allen Linguistik Studierenden von Anfang an zur Verfügung stehen. Die Module des E-Learning Kurses sind nach inhaltlichen Schwerpunkten aufgebaut, wobei sich die Schwierigkeit von Modul zu Modul erhöht.

3 Inhalt

Die E-Learning Inhalte führen in Lernmodelle ein, deren grundlegender Lernmechanismus auf Error-driven Learning basiert. Die Inhalte sind modular aufgebaut: Das Modul M1: Grundlagen in der R-Programmiersprache führt in die R-Programmiersprache ein. Dieses Modul ist für Studierende ohne Programmiererfahrung geeignet. Der Rest des Kurses ist in drei weiteren Modulen aufgeteilt. Jedes Modul ist in sich geschlossen und führt in ein R Paket zu Error-driven Learning ein. Weiter unten werden die vier E-Learning Module vorgestellt und die wichtigsten Lerninhalte werden stichpunktartig zusammengefasst:

- M1: Grundlagen in der R-Programmiersprache
 - Installation und Aufbau von R; Rechnungen, Datenstrukturen, Variablen, Funktionen, Vektoren, Data Frames, Listen, Kontrollstrukturen, Visualisierungen und Übungen
- M2: Einführung in Error-driven Learning mit edl
 - Theorie, Rescorla-Wagner Gleichungen, Trainingsdaten erstellen, Netzwerk trainieren, Visualisierungen, Lerneffekte (Cue-Competition, Blocking, Unlearning) und Übungen
- M3: Einführung in Naïve Discriminative Learning mit ndl
 - Theorie, Cue-Outcome Struktur, End-of-State Learning und Übungen
- M4: Einführung in Linear Discriminative Learning mit WpmWithLdl

- reelwertige Cue-Outcome Struktur, Semantische Vektoren, Lineare Abbildung, Rekonstruktion von Wortformen, Evaluation und Übungen
- Material
 - Skripte, Visualisierungen, Verständnisfragen, Multiple Choice, Schreib-deinen-eigenen-Code-Aufgaben, Videoanleitungen, Drag-and-Drop, Kreuzworträtsel...

Dabei sind edl und ndl Implementierungen derselben Theorie, während WpmWithLdl sich etwas unterscheidet. Die Module sind unabhängig voneinander. Die Schwierigkeit erhöht sich jedoch von Modul zu Modul.

Die Inhalte bestehen aus einer Reihe an Erklärungsskripts, Visualisierungen, Videotutorials, Programmieraufgaben und interaktiven Aufgaben, welche mit H5P erstellt wurden. Dazu gehören: Kreuzworträtsel, Single/Multiple Choice Aufgaben, Drag and Drop Aufgaben, und Schreibe-deinen-eigenen-Code Aufgaben. Einige Beispiele sind in Abschnitt 10 enthalten.

4 Umsetzung

Zur Umsetzung wurde den studentischen Mitarbeiter*innen Materialien zur Vorbereitung auf die Erstellung der E-Learning Inhalte zur Verfügung gestellt. Die didaktische Aufarbeitung dieser Materialien, d.h. Erklärungen, Beispiele, Aufgaben etc. waren Aufgabe der Hilfskräfte. Die ersten **zwei** Monate waren daher der Vorbereitung, der inhaltlichen Einarbeitung und der Konzeptualisierung der Kursinhalte gewidmet. Die restlichen 10 Monate wurde an den Inhalten gearbeitet, d.h. es fanden Ideenumsetzung, Fehlerkorrektur und Erstellung der Übungsaufgaben statt. Dabei wurde jede Hilfskraft je zwei Modulen zugeordnet. Die Hilfskräfte trafen sich regelmäßig mit dem Projektleiter zur Fortschrittsbesprechung – entweder online oder in Präsenz. Zunächst fanden die Treffen monatlich statt, anschließend zwei mal im Monat. Alle Inhalte wurden auf Moodle erstellt. Die Aufgaben wurden überwiegend mit H5P erstellt, oder beinhalten Anwendungsbeispiele, Verständnisfragen, oder Schreib-deinen-eigenen-Code Aufgaben. Bei den Erklärungen wurde sich auf wissenschaftliche Artikel und Buchkapitel bezogen. Es wurde eindeutig auf alle externen Referenzen referiert, welche nach dem APA-Standard zitiert wurden.

5 Ergebnisse

Erste Rückmeldungen einzelner Tester*innen waren überaus positiv. Gelobt wurde der anfängerfreundliche Einstieg durch das erste Modul. Die erstellten Module wurden teils als umfangreich, aber inhaltlich angemessen bewertet. Allerdings wurde während des Projekts bereits recht früh festgestellt, dass das fünfte Modul, welches ursprünglich geplant war – Einführung in TiMBL, ein weiteres Lernmodell – während der Projektlaufzeit nicht realisierbar war. Auch war eine Evaluation durch Studierende während der Projektlaufzeit leider nicht möglich. In Zukunft ist eine realistischerer Einschätzung des Aufwands, mit samt genauerer Anweisung für Hilfskräfte notwendig. Eine Übersetzung der Inhalte ins Englisch wäre für Zukünftige vorhaben sinnvoll, da für viele Linguistik MA Studierende die Sprachbarriere ein Problem darstellt. Dennoch ist die Erstellung von deutschsprachigen E-Learning Inhalten sehr sinnvoll gewesen, da die E-Learning Plattform eine von wenigen deutschsprachigen Ressourcen zu der Arbeit mit den drei genannten Computer-

modellen ist. Der E-Learning Kurs wird in Zukunft für alle Kurse, die sich mit Aspekten der Morphologie, Syntax, Phonologie und Phonetik beschäftigen zur Verfügung gestellt.

6 Verfügbarkeit

Der Kurs wurde als Moodle-Kurs erstellt und ist unter folgendem Link abrufbar <https://moodle.phil.hhu.de/course/view.php?id=1488>. Das Passwort lautet **errordriven**. Die Archivdateien sind zudem auf osf.io/jgv8t hochgeladen und können von Anderen frei genutzt werden. Der E-Learning Kurs ist unter der Creative Commons Attribution – Namensnennung - Nicht-kommerziell - Weitergabe unter gleichen Bedingungen 4.0 International Lizenz lizenziert.

7 Ausblick

Bisher standen die Inhalte des E-Learning Kurses den Studierenden nicht zur Verfügung. Der nächste Schritt ist daher die tatsächliche Nutzung der Inhalte für verschiedene Kurse. Das Projekt wurde zunächst als deutschsprachiges Projekt konzipiert. Dies hatte zwei Gründe: Zum einen richten sich die Inhalte primär an Studierende des Linguistik-Bachelors – welcher hauptsächlich auf Deutsch unterrichtet wird. Zum anderen existierten bisher kaum deutschsprachige Ressourcen, die in die praktische Verwendung dieser Modelle einführen. Während der Projektarbeit stellte sich allerdings heraus, dass eine Englische Version für unter anderem internationale Studierende des Linguistik-Masters durchaus Sinn ergäbe. Eine Übersetzung der Kursinhalte in eine Englische Fassung wird daher in Zukunft angestrebt.

8 Autorenbeiträge

Severin Sieber (SeSi): 50%, Kseniya Rudakova (KR): 50%. Vorgesetzter und Korrespondenzautor: Erdin Mujezinovic (EM) – nach [CRedit taxonomy](#): Konzeptualisierung: SeSi, KR, EM Datenübernahme: EM Fördermittelerwerb: EM Untersuchung: SeSi, KR Methode: SeSi, KR, EM Projektverwaltung: SeSi, KR, EM Projektleitung: EM Visualisierung: SeSi, KR, EM Schreiben – erster Entwurf: EM Schreiben – Überprüfen & Editieren: EM

9 Danksagung

Das Projekt "Wir nutzen die Technologie! Erste Schritte in die Modellierung von linguistischen Daten" wurde von der E-Learning Förderfond der Heinrich-Heine-Universität Düsseldorf im Jahr 2023/2024 gefördert (siehe: <https://www.elearning.hhu.de/projekt-datenbank/mujezinovic-2023-ii>). Das Fördergeld wurde dem Antragsteller Erdin Mujezinovic verliehen. Für die Inhalte sind Severin Sieber und Kseniya Rudakova zuständig. Ein Dank gebührt auch Anfisa Pogorelova für das Testen der Inhalte.

10 Anhang

Wie sieht der Inhalt von actRounded aus (schematisch)?

`actRounded <- round(activations)`

	NP	PP
[1,]	0.91	0.09
[2,]	0.79	0.21
[3,]	0.91	0.09
[4,]	1.08	-0.08
[5,]	0.74	0.26
[6,]	0.88	0.12
[7,]	0.71	0.29
[8,]	0.98	0.02
[9,]	1.05	-0.05

	NP	PP
[1,]	1	0
[2,]	1	0
[3,]	1	0
[4,]	1	0
[5,]	1	0
[6,]	1	0
[7,]	1	0
[8,]	1	0
[9,]	1	0

	NP	PP
AccessOfRecaccessible	0	0
AccessOfRecgiven	2	-1
AccessOfRecnew	-1	2
AccessOfThemeaccessible	1	0
AccessOfThemegiven	-1	2
AccessOfThemeneu	1	0
AnimacyOfRecanimate	2	-1
AnimacyOfRecinanimate	-1	2
AnimacyOfThemeanimate	0	1
AnimacyOfThemeinanimate	0	0

★ 1/1



Abbildung 1: Single Choice Aufgabe (Modul M3)

Einschub: Matrix-Multiplikation und Matrizen als Lineare Abbildungen

Im folgenden wird ein Basiswissen über Matrix-Multiplikation vorausgesetzt. Hier ist eine kurze Zusammenfassung.

Das Produkt zweier Matrizen A und B ist beschrieben von folgender Formel: $c_{ij} = \sum a_{ik} b_{kj}$.

c_{ij} ist das Element in Zeile i und Spalte j der resultierenden Matrix. Es wird berechnet, indem wir jedes Element der i-ten Zeile in A mit dem korrespondierenden Element in der j-ten Spalte in B multiplizieren und von diesen Produkten die Summe bilden.

Damit zwei Matrizen multipliziert werden können, muss die zweite so viele Zeilen haben, wie die erste Spalten. Eine $n \times m$ Matrix können wir also mit einer $m \times k$ Matrix multiplizieren, und es kommt eine $n \times k$ Matrix heraus.

Schematisch:




Abbildung 2: Erklärung + Visualisierung (Modul M4)


$$\begin{pmatrix} 10 & 2 \\ 3 & 100 \end{pmatrix} \times \begin{pmatrix} 1 & -2 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} \boxed{12} & \boxed{-14} \\ \boxed{103} & 294 \end{pmatrix}$$

15 13 -12 -14 12 296 303 103 8 110

3/3

Abbildung 3: Drag und Drop (Modul M4)

Alles gemerkt? Test yourself: LDL



Across

3 WPM steht für Word and ? Morphology (8)

5 Die Abbildung von C auf S modelliert ... (13) ⓘ

6 Die Matrix F (bei $S = C \cdot F$) nennen wir eine lineare ... (9)

Down

1 Zentrale Funktion in WpmWithLdl zu u.A. Berechnung der vorhergesagten Matrizen (14)

2 Name der Matrix mit den vorhergesagten semantischen Vektoren (4) ⓘ

3 Die Abbildung von S auf C modelliert ... (10) ⓘ

4 Im Gegensatz zur rein binären Kodierung in NDL sind semantische Vektoren in LDL ... (10) ⓘ

Abbildung 4: Kreuzworträtsel (Modul M4)



Lösung im Video



Versuche es zuerst selber!

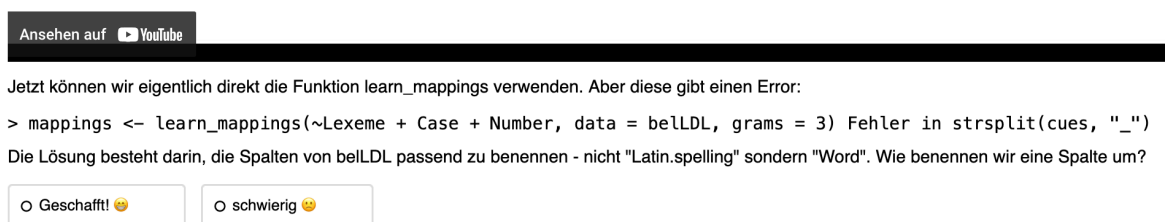


Abbildung 5: Videoanleitungen (Modul M4)